

時系列データマイニングによる行動推定技術の開発

杉村博* 高見澤 聖子** 松本 一教**

*神奈川工科大学 工学教育研究推進機構 スマートハウス研究センター

**神奈川工科大学大学院 情報工学専攻

Applying Methods of Time-Series Datamining into Activity Recognition

Hiroshi SUGIMURA*, Seiko TAKAMIZAWA**, and Kazunori MATSUMOTO**

*Smart House Research Center, Kanagawa Institute of Technology

**Course of Information and Computer Sciences, Graduate School of Kanagawa Institute of Technology

Owing to the recent progress of sensor technologies, the applicability of activity recognition is widely spreading. In particular, the popularization of mobile and smart phones which are equipped several kinds of sensors including accelerometers further boost up the applicability. In this study, we note that a daily human activity is composed of naive actions. By using this fact, a simple recognition method over naive activities can be composed to recognize complex activities. In order to prove this assumption, we develop a naive recognition tool based on the decision tree learning, and then it is extended over composed and complex activities. We also propose data processing methods, including clustering and flexible matching, which are necessary in the first phase of the recognitions. The proposed method is demonstrated through experiments.

キーワード：行動推定，行動識別，加速度センサー，データマイニング，決定木

(Behavior estimation, Behavior classification, Accelerometer, Data mining, Decision tree)

1. はじめに

携帯電話やスマートフォンにもある程度の精度を持つ加速度センサー等が常識的に装備されるようになった。このセンサーで得られたデータを用いて、行動推定を行う技術の開発が進められている。行動推定が可能になることで、利用者の次の行動を事前に予測することも可能となり、それを活用した高度なサービス提供が期待できる。例えば、利用者の今の行動から、数秒先の行動を予測して、照明を自動的に点灯させること等が考えられる。省エネルギーへの貢献につながることは当然であるが、老人や体に不自由な人のいる環境では、転倒防止などの安全性を高めることにも貢献できると期待できる。行動推定だけではなく、利用者に関する他の情報も総合することにより、さらに高度なサービス提供につながっていくことも期待される。

本研究では、スマートフォンに標準的に装備されている加速度センサーと GPS 情報を利用した開発を行った。最近では超音波センサーや赤外線センサーなど各種センサーの小型化や低価格化が進んでいるため、他の種類のセンサーも同時に利用する手段も考えられる。しかし、スマートフ

オンというものは誰でもが日常的に持っている装備だけを利用できる環境で、どの程度の行動推定精度が達成できるかを追求することには十分意味があると考えられる。

人間の最も基本的で単純な行動である「立つ」、「歩く」、「座る」などは、パターンが明確であり、加速度センサーだけによる高精度の推定が可能である。そこで本研究では、基本行動の識別技術をベースとして、その上に順次複雑な行動の識別技術を構築していくというアプローチを採用した。基本行動の識別には、筆者らが以前から研究を進めてきている時系列データからのデータマイニング技術がこのような目的に有効であることを実験により実証する。

2. 想定する環境と従来技術

(2.1) 各種センサーと利用環境

カメラに取得される光学的な情報を利用する方法が研究されている。従来はモーションキャプチャのように特殊で高価な機器が必要であったが、最近では家庭用機器である Xbox を利用する方法もさかんに研究されている。センサー類を対象となる人間が身に着ける必要がなく、長時間にわ

たる推定には有利と予想できる。しかし、行動範囲が広い場合や、多人数が視野に入る場合には不利となる。また、品川らの研究では⁽¹⁾独居老人の部屋のいくつかの箇所に赤外線センサーを設置して、そのパターンを見ることで非日常の状態を検出する手法を研究している。この方法では、通常とは異なる状況の検出が主目的であるため、具体的な行動推定には不利となる。

ウェアラブルセンサーを用いる方法では、対象者が身に着けることにより、広い範囲での測定が可能となり、多人数がいる場合、対象者だけの情報を得ることが容易である。しかし、センサー装着が対象者に負荷となる場合もあるため、とくに加速度センサーを利用する研究が数多くある。このような研究状況を踏まえて、本研究ではスマートフォンの加速度センサーを利用することとした。

(2.2) 加速度センサー装着に関する検討

加速度センサーを用いる場合、身体のいずれの場所に何個装着すれば良いかという問題がある。Bao らの研究⁽²⁾によれば、右手首と左腿の2箇所への装着により、約20種類の日常行動に対してほぼ80%の識別能力が得られることが示されている。また、田端らの研究⁽³⁾では識別対象とする行動毎にセンサーの位置を変えるなどして最適な装着位置を実験的に検討している。

センサーのサンプリング周波数に関しては、研究毎に性能が異なっているが、多くは50Hz以上でのデータ獲得を行っている。しかし、基本的な人間の行動推定に必要なサンプリング周波数の値は諸説ある。川原らの研究⁽⁴⁾においては2軸の加速度センサーで10Hz以下のサンプリングにより、4種類の基本的な行動に対して、ほぼ100%の精度を達成している。このように、行動推定に必要なセンサーの性能、装着場所、個数については未だに結論が出ていない状況である。

(2.3) 本研究での実験環境

容易に入手可能なスマートフォンに標準されている3軸加速度センサと方位センサを利用した。機器購入などの制約により、東芝製 REGZA Tablet AT3S0 を用いた。重量は約750グラムである。これを1個大腿部に装着して利用した。センサの値は100ms毎に収集するようにしている(図1)。



図1 タブレットの装着

(2.4) 時系列データマイニング

データマイニングとは、大規模なデータから有効な知識を抽出する技術である⁽⁵⁾。脳の情報処理を模倣するニューラルネットワーク⁽⁶⁾や生物の進化過程を模倣する遺伝的アルゴリズム⁽⁷⁾などの技術も開発されている。このような自然化の仕組みをまねた方式では、精度の高い知識を得ることが多数報告されている。しかし、獲得された知識はブラックボックス的なものであり、その内容を人間が理解することは難しいという問題を含んでいる。一方、データに潜む知識を分かりやすく表現することに重点を置いた手法もある。相関ルールマイニング⁽⁸⁾とよばれる方法では、データの中に埋もれているデータ間の同時生起に関するパターンをIF THEN 型のルール知識として抽出するようになっている。決定木学習⁽⁹⁾は古くから多くの研究がなされてきた技術である。データがいくつかのクラスに分類されているとき、未知のデータを最も効率良く分類するための知識を決定木として獲得する方法である。決定木の複雑な枝分かれを精度をさほど犠牲にすることなく整理してコンパクト化する技術、コンパクト化された決定木からIF THEN 型のルールを抽出する技術が開発されているため、この方法でも人間が理解しやすい知識を得ることができる。このような点に着目して、本研究では決定木にもとづくデータマイニング方式をベースとして、行動推定に必要な種々の技術を開発して組み込むこととした。

3. 基本行動と上位行動

(3.1) 行動推定方式の概要

従来研究では⁽⁷⁾人間の行動が完結する時間に応じて、短期型から長期型に分けた手法を開発しているものがある。本研究では、この分類に従えば短期型の行動を対象として、さらにそれを基本行動と上位行動とに分割した。両者の区別は以下の通りである。

- ・ 基本行動: 5秒以内に完結する動作であり、「立ちがる」、「立っている」、「座る」、「座っている」、「歩く」、の5種類とする。
- ・ 上位行動: 50秒以内で完結する動作であり、上記の基本行動を組合わせたもの。今回は室内で行う典型的な行動の中から、「PC作業」、「テレビ視聴」、「清掃」、「料理」、「本箱の利用」の5種類を対象とした。

今回用いているタブレットは3軸のデータを取得するが、データの概要を図2に示している。上は「立ち上がる」基本行動であり、下は椅子に「座る」という基本行動である。ともに同一被験者による10回のデータを示しているが、毎回加速度の大きさやパターンの時間軸上でのブレが生じていることが直ちに分かる。上位行動では、このような基本行動のデータが10個分並んだものとなる。次節で説明するが、このように同じ動作でも正確な一致はしないために、ブレに対して頑強な推定方式が必要となる。

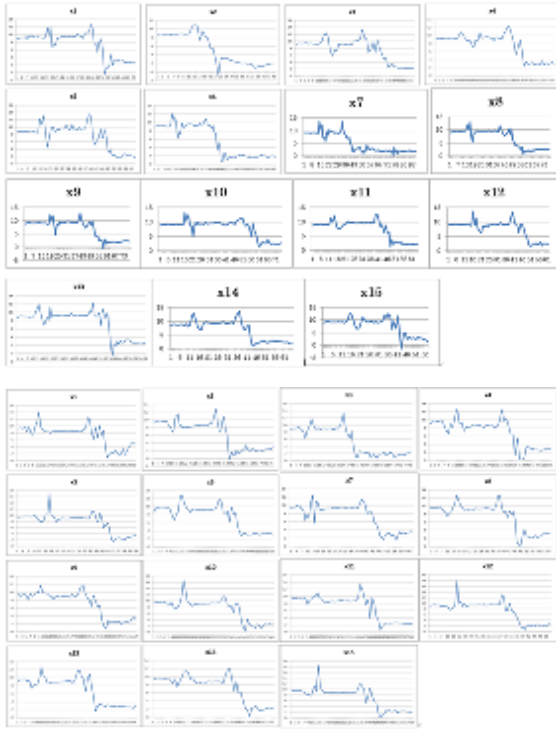


図2 基本行動データ収集例（一軸のみ）

(3.2) 行動データのテンプレートパターン作成

行動推定のために必要となるテンプレートパターンを作成するための手順を図3に示す。最初に被験者から各基本行動のデータを収集する。今回の実験では、サンプリングを100msとして5秒間のデータを収集している。次のステップでは、各基本行動のデータを事前に与えたクラスタ数になるまでクラスタリングを行う。

Procedure : constructing template patterns

Input: $D = \{D_b \mid \text{data of naïve behavior } b\}$,
N number of clusters

Output: template patterns T

begin

for each naïve behavior b

divide D_b into N clusters D_b^N using k-means

for each naïve behavior b

output clusters D_b^N as the template for b

end

図3 テンプレート作成の手順

このときに用いる k-means 法については、図4に示している。クラスタリングを行う理由は、毎回の行動にはブレがあり、得られたデータにもそれが反映されている。クラスタリングを行うことにより、類似のデータを収集し、その代表を取ることによって最も典型的と見なせるデータを得ている。このとき、先に図2で見たように、行動データには加速度方向のブレだけではなく、時間軸方向のブレも含まれている。従って、データを時間軸方向で伸縮させながら、類似データをクラスタリングしていく必要がある。この目

的のために DTW (Dynamic Time Warping) というマッチング方法を採用している。図5にこの方式の概念図を示し、図6にこの方法で計算される DTW 距離の定義を示す。

Algorithm: k-means

input: The number of clusters k and a database containing n objects.

output: A set of k clusters that minimizes the squared-error criterion.

begin

arbitrarily choose k objects as the initial centroids;

do

assign each object to the cluster to which the object is the most similar, based on the mean value of the objects in the cluster;

update the cluster means;

// (i.e., calculate the mean value of the

// objects for each cluster.)

while no change;

end

図4 k-means 法の処理概要

各々の長さが n, m である 2 つの時系列データ p, q に対して、 $i \leq n, j \leq m$ 番目のデータに対する DTW 値が図6で求められる。ここで、 s, t, u は各々時間軸上でデータを縮小するコスト、データの値の差、データを伸長するコストである。これらのコストは DTW を適用する際のパラメータとして調整すべきものであり実験により定める。




図5 テンプレートパターン作成の手順

$$f(p_i, q_j) = \min \begin{cases} f(p_i, q_{j-1}) + s \\ f(p_{i-1}, q_j) + t \\ f(p_{i-1}, q_{j-1}) + u \end{cases}$$

図6 DTW の計算式(s, t, u はコスト)

クラスタ数 N は事前に与えるようにしているが、これを自動的に決定できるようにした x-means 等のクラスタリング手法もある。ここでは、その後のデータ解析を容易にするために自動的な手法は採用していない。後に述べる実験により、クラスタ数は、基本行動から取り出す知識の品質に直接影響を与えることが分かっており、ある程度大目に与えることで精度を高めることができる。この件については、後に改めて議論する。

4. データマイニングでの知識獲得

(4.1) 基本行動推定の知識獲得

基本行動のテンプレートを作成した後は、行動推定を行うための知識をデータマイニングにより獲得する。単純な方法では、テンプレートと与えられた行動データとのマハラノビス距離を計算して、最も近くに位置するテンプレートが所属する基本行動と判定する方法がある。本研究では、より正確な知識をえること、および将来の研究でさらに多くの基本行動を追加した場合への対応容易性を考慮して、決定木によるデータマイニングを適用することにした。この概念図を図7および図8に示す。






図7 クラスタリングによるセントロイド抽出

1. 基本行動の訓練データ取得



2. クラスタリングで行動毎のセントロイド発見



3. 決定木により未知データの分類知識獲得



図8 データマイニングによる決定

決定木学習では、表1に示すテーブル形式のデータを入力とする。テーブルの各列を属性とよび、列に入っている値を属性値とよぶ。属性の中で1つだけはクラス属性とよばれ、その値がクラスである。本実験では、クラスとして基本行動のタイプが入る。各属性値は離散値でも連続値のいずれでも与えることができる。

表1 決定木に与えるデータ形式

属性1	属性2	クラス属性
v_1^1	v_1^2	c_1
...
v_1^n	v_1^n	c_k

従来から決定木を時系列データなどの数値データに適用した研究は多数ある。多くは、時刻 i における観測値をそのまま属性 v_i として、得られた値を属性値とする方法である。すなわち、元の時系列データ $s_i = \langle v_1, v_2, \dots, v_n \rangle$ そのままテーブルにする方法である。本研究では、属性 ij として、基本行動 i の第 j クラスとの DTW 値 (すなわち相違度) を取ることとした (図9)。

訓練データ	属性 v_1			属性 v_k		属性 v_n	クラス
	v_1^1					v_n^1	歩く
	v_1^2					v_n^2	歩く
	v_1^m					v_n^m	立つ

基本行動クラス セントロイド 基本行動クラス セントロイド

図9 本研究で決定木に与えるデータ

決定木学習を行った結果、図10に示す決定木が獲得された。これを用いて次のように、与えられたデータの基本行動を推定することができる。

- (1) 与えられたデータに対して、基本行動の各クラスに対する DTW 値を計算し表1のテーブル形式にする
- (2) 決定木に与えクラスを定める

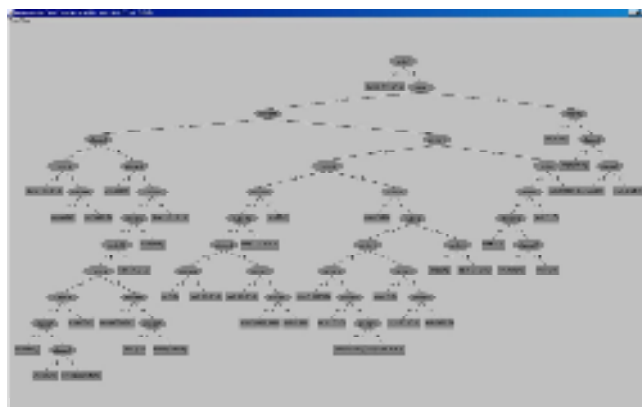


図10 獲得された決定木

(4.2) 基本行動推定の評価

本方式の有効性を実証するための実験を行った。このときの評価尺度としては、適合率 (precision) と再現率 (recall) に着目した。適合率とは、手法により基本行動 x であると判定された N_x 件が正解である割合を示している。 N_x 中の P_x が正解で残る $N_x - P_x$ は誤判定であれば、 P_x/N_x が precision となる。もし全く誤りを含まないならば 1.0 であり (少なくとも 1 件は結果を出力して)、正確が含まれないなら 0 となる。再現率は、基本行動 x に属する全データが U_x であるとき、そのうちのどの程度がこの手法で判定された

かを示し、 N_x/U_x で求められる。判定漏れなく全てを求めることができているれば 1.0 であり、全く判定できなければ 0 となる。このうちのいずれかのみを向上させることは比較的容易であるが、両者を共に 1.0 に近づけることは難しいので、このような手法の精度判定に相応しい。結果を表 2 に示す。

表 2 基本行動識別の精度

適合率 (precision)	再現率 (recall)	基本動作
0.93	0.96	座る
0.81	0.98	立つ
0.99	0.92	立っている (保持)
0.95	0.78	歩く
0.99	1.0	座っている (保持)

(4.3) 上位行動判定のためのデータマイニング

上位行動とは基本行動を 10 個程度連結した一連の動作であり数十秒で完結する。このための知識獲得は、先に述べた基本行動に対する知識獲得結果をベースとして、その上に基本行動シーケンスを識別する知識を構築するという方法で構築する。その概念図を図 12 に示す。まず上位行動の訓練データを取得し、それを基本行動のデータ候補へと分割する。基本行動は長さが 5 秒程度という情報を利用して、相互に重なりがある区間への分割として見逃しを防ぐ二様にしている。基本行動パターンに分割できれば、それを先に学習しておいた決定木の知識を用いて基本行動を確定する。こうして、元の訓練データに対して、基本行動の列を対応付けることができる。このような訓練データと基本行動列から構成される情報が決定木に与えるデータとなる。




図 11 上位行動の識別知識獲得

(4.4) 付加情報の利用

スマートフォンには GPS や方位センサーなども装備されており、それらの情報も容易に取得できる。ここでは、加速度に関するデータだけでなく、他のセンサーからのデータも併用する方法についての基本的な検討を行った。

方位センサーにより、被験者が向いている方向を取得して、それを加速度センサーデータに付加することとした。

実験場所で TV、キッチン、本棚のある場所の情報は与えていないため、方向だけから行動を識別することは不可能である。ただし、この実験を通じて、これらの什器がある場所に移動はないとして行っている。表 3 にその結果を示す。

表 3 上位行動の識別実験結果

行動データ & 方角データ	行動データ	方角データ	上位行動
0.71	0.45	0.55	PC 操作
0.64	0.50	0.49	TV 視聴
0.79	0.46	0.54	料理
0.80	0.50	0.54	本棚探索
0.84	0.80	0.50	掃除

5. 結論

本研究では、数秒間の短時間で完結する単純な人間の行動を基本行動とよび、それを加速度センサーから識別するための知識を決定木によるデータマイニングで獲得した。実験により適合率も再現率も 0.9 を超える精度が達成できており、十分実用に耐える結果が得られた。この方式をベースとして、1 分程度の連続した行動（上位行動）を識別するための知識獲得を行う方法も開発した。加速度センサーの情報だけでは、0.5 程度の精度しか得られなかったが、方位センサーの情報も併用することにより、精度を 0.8 程度まで容易に高められることが判明した。本研究での実験により、スマートフォンに標準装備される程度のセンサーでも一定の精度での行動識別が可能となることが明らかになった。今後はより豊富な他の情報の併用方法やより長期の行動識別について研究を進める計画としている。

文 献

- (1) 品川佳満, 岸本俊夫, 太田茂: 行動パターン分類による独居高齢者の非日常検出, 川崎医療福祉学会誌, Vol.15, No.1, pp.175-181 (2005)
- (2) L. Bao and S.S. Intille: "Activity recognition from user-annotated acceleration data", in Proc. of Pervasive 2004, Vol. LNCS 3001, A. Ferscha and F. Mattern(Eds.), Springer-Verlag, Berlin Heidelberg, pp. 1-17(2004)
- (3) 田淵勝宏他: 「加速度センサを用いた日常行動識別におけるデータ収集条件の識別性能への影響評価」, 電子情報通信学会技術研究報告, PRMU, パターン認識・メディア理解, Vol. 106, No.73, pp. 43-48 (2006)
- (4) 川端圭博他: 「小型無線センサを用いたコンテキスト推定とそのアプリケーション」, 特定非営利活動法人ウェアラブルコンピューティング研究会報告, Vol. 1, No. 3, pp. 2-6(2005)
- (5) J.Han, M.Kamber, and J.Pei: "Data Mining, Concepts and Techniques", Morgan Kaufmann (2011)
- (6) H. Sugimura, and K. Matsumoto: "Classification system for time series data based on feature pattern extraction", The 2011 IEEE International Conference on Systems, Man, and Cybernetics (SMC 2011), pp. 1340-1345(2011)
- (7) 宮崎雄一郎他: 「ユーザの行動に合わせたサービス実現のための行動推定技術の開発」, NTT DoCoMo テクニカル・ジャーナル, Vol. 17, No. 3, pp. 55-61(2009)