

データマイニング手法によるセンサーデータからの行動推定

藤澤将貴^{†1} 杉村博^{†2} 高見澤聖子^{†1} 松本一教^{†1}

本研究の目的は、人間の簡単な行動の推定手法を開発することである。本手法では、スマートフォンに内蔵された加速度センサーだけの情報を使っていくつかの基本行動に関してかなりの精度で推定可能であることが明らかになった。我々の最終的な目的は、現在および予想される将来の推定行動から、例えば、集中してテレビを見ていないという推測が可能となり、テレビが電源を切る提案をするというシステムを開発する。

Datamining based Activity Recognition from Getting Data

MASAKI FUJISAWA^{†1} HIROSHI SUGIMURA^{†2} SEIKO TAKAMIZAWA^{†1}
KAZUNORI MATSUMOTO^{†1}

The aim of this study is a development of a recognition tool of human naive activities. The applicability of this method is wide in that it only uses sensing data with accelerometer equipped in a standard smartphone. With a use of this tool our final purpose is recognition of a consumer's complex activities, which can help us to estimate future activities of him. By using such estimation, electronics devices in a home can be operated automatically in energy saving manner. Towards this goal, this paper first proposes data processing methods, including clustering and flexible matching, and then show a data mining recognition method over the processed data. We also demonstrate experimental results and show the effectiveness of this method.

1. はじめに

古くから人がどのような動きをしているか判別する研究は多くされてきた。例えば Jhonasson[1]は人が何かしら動作をするときに動く主要関節部分に光源を取り付け、被験者に静止している状態と動いている状態を見せた。その結果、静止しているときはただの光の集合にしか見えなかったが、ある動作を行った途端、被験者はその行動が人の歩行行動であると認識した。このような知覚をもたらす情報はバイオリジカルモーションと呼ばれ、人の行動だけでなく、動作に含まれる感情や性別までも知覚させることができる。

このバイオリジカルモーションはモーションキャプチャ装置を使用して計測を行う。現在は主にスポーツ選手の体の動きのデータを収集し解析を行い有効に活用する目的や、アニメーションやゲームに登場するキャラクターの人間らしい動きの再現に使われている。しかし、これは比較的狭い範囲かつ専用のスタジオで使用する事が多く、また、装置自体の脱着にも苦勞するという問題点がある。

これらを踏まえ、本研究では、スマートフォンに搭載されている加速度センサーを利用し人の行動を推定する手法を提案する。精度はモーションキャプチャ装置を使用した時よりも落ちる可能性がある。しかし、日常生活でデータを収集しやすく、そのデータを解析し有効に使える場合は現在の情報化社会のなかには数多く存在する。そのため、ス

マートフォンという多くの人が日常的に持っている装備だけを利用した環境でどの程度の基本行動推定の精度が得られるかを追求することには、十分意味があると考えられる。

本論文では、筆者らが以前から研究を進めている時系列データマイニングが行動識別にも有効であることを、日常生活において多くみられる「座っている状態」「背もたれに寄りかかっている状態」「机に突っ伏している状態」「横になって寝ている状態」「歩いている状態」を想定した基本行動識別実験を通して実証する。

2. 従来技術と想定する環境

2.1 各種センサーと利用環境

カメラに取得される光学的な情報を利用する方法が研究されている。従来はモーションキャプチャのように特殊で高価な機器が必要であったが、最近では家庭用機器であるXboxを利用する方法も盛んに研究されている。センサー類を対象となる人間が身に着ける必要がなく、長時間にわたる推定には有利と予想できる。しかし、行動範囲が広い場合や、多人数が視野に入る場合には不利となる。また、品川らの研究[2]では独居老人の部屋のいくつかの箇所に赤外線センサーを設置して、そのパターンを見ることで非日常の状態を検出する手法を研究している。この方法では、通常とは異なる状況の検出が主目的であるため、具体的な行動推定には不利となる。

ウェアラブルセンサーを用いる方法では、対象者が身に着けることにより、広い範囲での測定が可能となり、多人数がいる場合、対象者だけの情報を得ることが容易である。しかし、センサー装着が対象者に負荷となる場合もあるた

^{†1} 神奈川工科大学大学院 情報工学専攻
Course of Information and Computer Sciences, Graduate School of Kanagawa Institute of Technology.

^{†2} 神奈川工科大学 工学教育研究推進機構 スマートハウス研究センター
Research Smart House Research Center, Kanagawa Institute of Technology

め、とくに加速度センサーを利用する研究が数多くある。このような研究状況を踏まえて、本研究ではスマートフォンの加速度センサーを利用することとした。

2.2 加速度センサー装着に関する検討

加速度センサーを用いる場合、身体のいずれの場所に何個装着すれば良いかという問題がある。Bao らの研究[3]によれば、右手首と左腿の2箇所への装着により、約20種類の日常行動に対してほぼ80%の識別能力が得られることが示されている。また、田端らの研究[4]では識別対象とする行動毎にセンサーの位置を変えるなどして最適な装着位置を実験的に検討している。

センサーのサンプリング周波数に関しては、研究毎に性能が異なっているが、多くは50Hz以上でのデータ獲得を行っている。しかし、基本的な人間の行動推定に必要なサンプリング周波数の値は諸説ある。川原らの研究[5]においては2軸の加速度センサーで10Hz以下のサンプリングにより、4種類の基本的な行動に対して、ほぼ100%の精度を達成している。このように、行動推定に必要なセンサーの性能、装着場所、個数については未だに結論が出ていない状況である。

2.3 本研究での実験環境

容易に入手可能なスマートフォンに標準されている3軸加速度センサーを利用した。機器購入などの制約により、富士通製スマートフォン F-12C を用いた。重量は約107グラムである。これを1個胸ポケット部に装着して利用した(図1)。センサーの値は66ms毎に収集するようにしている。




図1 スマートフォンの装着

2.4 時系列データマイニング

データマイニングとは、大規模なデータから有効な知識を抽出する技術である[6]。脳の情報処理を模倣するニューラルネットワーク[6]や生物の進化過程を模倣する遺伝的アルゴリズム[6]などの技術も開発されている。このような自然化の仕組みをまねた方式では、精度の高い知識を得ることが多数報告されている。しかし、獲得された知識はブラックボックス的なものであり、その内容を人間が理解することは難しいという問題を含んでいる。一方、データに潜む知識を分かりやすく表現することに重点を置いた手法もある。相関ルールマイニング[7]とよばれる方法では、デ

ータの中に埋もれているデータ間の同時生起に関するパターンを IF THEN 型のルール知識として抽出するようになっている。決定木学習[7]は古くから多くの研究がなされてきた技術である。データがいくつかのクラスに分類されているとき、未知のデータを最も効率良く分類するための知識を決定木として獲得する方法である。決定木の複雑な枝分かれを、精度をさほど犠牲にすることなく整理してコンパクト化する技術や、コンパクト化された決定木から IF THEN 型のルールを抽出する技術が開発されているため、この方法でも人間が理解しやすい知識を得ることができる。このような点に着目して、本研究では決定木にもとづくデータマイニング方式をベースとして、行動推定に必要な種々の技術を開発して組み込むこととした。

3. システム構成

3.1 システムのイメージ

システムのイメージを示す(図2)。事前に決めた推定する行動の加速度センサーデータを、テンプレートデータ作成のために取得する。取得したセンサーデータから特徴を抽出し、この抽出した特徴がテンプレートデータとなる。ユーザがテレビを視聴し送信される加速度センサーのデータから、テンプレートデータとマッチングを行い、行動を推定する。

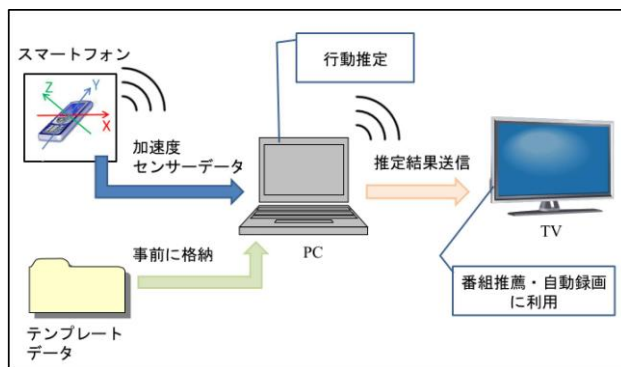


図2 システムイメージ

3.2 基本行動推定方式概要

従来研究[8]では、人間の最も基本的で単純な行動である「座る」、「座っている」、「立つ」、「立っている」、「歩く」の5種類を推定していた。本研究では、日常生活において多くみられる姿勢の中から、「座っている状態」、「背もたれに寄り掛かっている状態」、「机に突っ伏している状態」、「横になって寝ている状態」の4種類と、例外として「歩いている状態」の1種類、合計5種類(図3)を推定する。



図 3 測定する状態

今回使用するスマートフォンは、3 軸のデータを取得する。データの概要を示す(図 4)。同一被験者の 5 秒ごとの「歩く」という基本行動である。毎回同じ動作をしているが、加速度の大きさやパターンの時間軸上でのブレが生じていることがわかる。

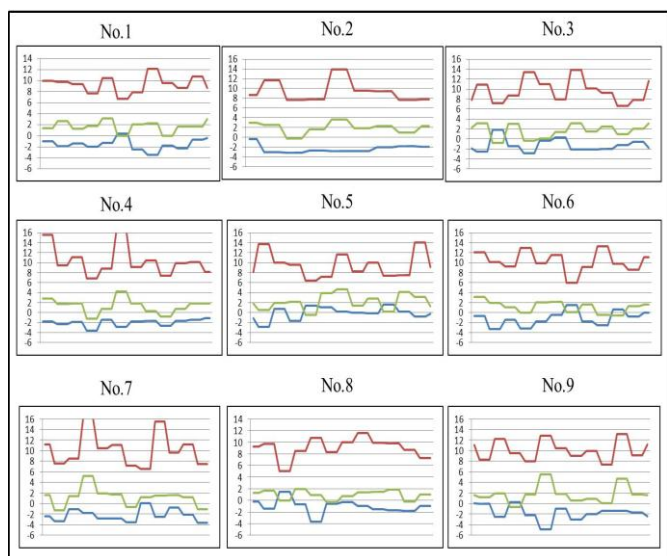


図 4 データ収集例(3 軸)

行動推定のために必要となるテンプレートパターンを作成するための手順を示す。最初に被験者から各行動のデータを収集する。今回の実験では、サンプリングを約 66ms として 5 秒間隔のデータを収集している。次のステップでは、各行動のデータを事前に与えたクラスタ数になるまでクラスタリングを行う。クラスタリングを行うことで、類似データでまとめ、その代表的な取ることで、最も典型的なデータを得ることができる。

本手法では、クラスタリング手法として、 k -means 法を適用した[9]。このアルゴリズムを示す(図 5)。クラスタ数は事前に与えるようにしているが、これを自動的に与える x -means 等のクラスタリング手法もある。今回は、その後のデータ解析を容易にするために自動的な手法は採用していない。後に述べる実験により、クラスタ数は、行動から取り出す知識の品質に大きな影響を与えることがわかっていいためである。

Algorithm: k -means

input: The number of clusters k and a database containing n objects.

output: A set of k clusters that minimizes the squared-error criterion.

begin

arbitrarily choose k objects as the initial centroids;

do

assign each object to the cluster to which the object is the most similar, based on the mean value of the objects in the cluster;
update the cluster means;
// (i.e., calculate the mean value of the // objects for each cluster.)

while no change;

end

図 5 アルゴリズム

3.3 行動推定の知識獲得

本手法では、テンプレートデータに対し、より正確な知識を得ること、および将来の研究でさらに多くの基本行動を追加した場合への対応の容易性を考慮して、決定木によるデータマイニングを適用する。この概念図を示す(図 6)。

まず、基本行動の訓練データ取得では、収集したセンサーデータに対して、それが表している行動を対応させる。つまり「このデータは座っているである」というような対応付けを行う。次に、クラスタリングによるセントロイド抽出では、センサーデータ全体をクラスタリングにより、類似と見なすことができるいくつかのグループに分割する。各グループの中心であるセントロイドが、各グループの代表であるとして、この学習での特徴量となる。決定木による基本行動分類器作成では、セントロイドとの類似性を属性値として、あるデータがどの基本行動であるかを推定する決定木を学習する。




図 6 データマイニングによる決定

決定木学習では、表 1 テンプレートファイルで用意したスタイルに示すテーブル形式のデータを入力とする。テーブルの各列を属性と呼び、列に入っている値を属性値と呼ぶ。属性の中で 1 つだけはクラス属性と呼ばれ、その値がクラスである。本実験では、クラスとして基本行動のタイプが入る。各属性値は離散値でも連続値のいずれでも与えることができる。

表 1 テンプレートファイルで用意したスタイル

attribute ₁	attribute ₂	class attribute
v_1^1	v_1^2	c_1
...
v_1^n	v_1^n	c_k

従来から決定木を時系列データなどの数値データに適用した研究は多数ある。多くは、時刻 i における観測値をそのまま属性 v_i として、得られた値を属性値とする方法である。すなわち、元の時系列データ $si = \langle v_1, v_2, \dots, v_n \rangle$ を、そのままテーブルにする方法である。本研究では、属性 ij として、基本行動 i の第 j クラスタとの DTW (Dynamic Time Warping) 値 (すなわち相違度) を取ることにした (図 7)。




図 7 本研究で与えるデータ

4. 基本行動推定の評価実験

まず、決定木に与えるセントロイド数が 1 つごとの基本行動推定性能を示す (図 8)。セントロイド数が 12 のとき、12 より少ない数のセントロイド数よりも推定性能が低くなっている部分があることがわかる。これは、本手法はクラスタリングの結果次第で、セントロイド数が多いほど、推定精度が高くなるわけではないことを示している。




図 8 セントロイド数ごとの推定性能

次に、表 2 に決定木に与えた属性のセントロイド数が 12 個のときの confusion matrix を示し、表 3 にセントロイド数が 13 個のときの confusion matrix を示す。sit が「座っている状態」、back が「背もたれに寄り掛かっている状態」、desk が「机に突っ伏している状態」、recline が「横になって寝ている状態」、walk が「歩いている状態」を表している。セントロイド数が 12 個のときは「背もたれに寄り掛かっている状態」が推定することができないということがわかる。セントロイド数が 13 個のときは、全体的に高精度で推定できることがわかる。これは、クラスタリングのクラス数次第で、基本行動から取り出す知識の品質に大きな差が出てしまうことを示している。この問題の解決のために、セントロイド数が異なるクラスタリング結果複数を決定木に与えれば、推定性能が向上する可能性がある。

表 2 セントロイド数 12 個の confusion matrix

	推定する行動					推定性能
	sit	back	desk	recline	walk	
sit	695	0	0	0	0	100%
back	0	0	0	458	236	0%
desk	0.	0	697	0	0	100%
recline	0	0	0	697	1	99.9%
walk	1	0	0	0	695	99.9%

表 3 セントロイド数 13 個の confusion matrix

	推定する行動					推定性能
	sit	back	desk	recline	walk	
sit	695	0	0	0	0	100%
back	0	686	0	8	0	98.8%
desk	0.	0	697	0	0	100%
recline	0	142	0	556	0	79.7%
walk	0	1	0	0	695	99.9%

本研究の有効性を実証するための実験を行った。このときの評価尺度としては、適合率 (precision) と再現率 (recall) に着目した。precision とは、判定した行動のうち、正解したものの割合を示す。判定したものが 0 であった場合を除き、判定したものが全て正解に含まれる場合、最高値の 1.0 を取り、正解が 1 つも含まれないならば 0 となる。recall とは、本来の行動として判定されるべきもののうち、どの程度が判定されたかを示す。この値が 1.0 ならば、判定漏れがなく、全てを判定できたことになり、まったく判定できなければ 0 となる。このうちの一方のみを向上させることは比較的容易であるが、両者を共に 1.0 に近づけることは難しいのでこのような手法の精度判定に相応しい。筆者が調べた中で、一番推定精度が高かった結果を表 4 に示す。

表 4 行動推定の精度

precision	recall	推定する状態
0.92	0.97	座っている
1.0	1.0	背もたれに寄り掛かっている
1.0	1.0	横になって寝ている
0.97	0.91	机に突っ伏している
0.98	0.97	歩いている

5. 結論と将来の課題

本研究では、スマートフォンに内蔵された加速度センサーだけの情報を使っていくつかの基本行動に関してかなりの精度で推定可能であることが明らかになった。スマートフォンの普及率を考慮すれば、実施的に本システムの利用

者が負担するコストはゼロに近いといって良い。従って、一般家庭に容易に導入可能なシステムである。さらに複雑な行動を識別するためには、より高度なデータマイニング手法を適用したり、他の情報を併用したりする必要があると思われる。そのための検討は今後の課題である。

本システムを利用することで家庭内での行動推定が可能となれば、例えば、集中してテレビを見ていないという推測が可能となり、電源を切るという提案をシステムが出すことができる。同様に、現在および予想される将来の推定行動から判断することで無駄な電気製品の使用を停止するように助言することができるとと思われる。スマートハウスに代表されるようなこれからの節電技術を支えるベース技術として本研究を発展させていく計画である。

参考文献

- 1) G. Johansson.: Visual Perception of Biological Motion and a Model for Its Analysis, Perception and Psychophysics, Vol.14, No2, pp.201-211 (1973).
- 2) 品川佳満, 岸本俊夫, 太田茂: 行動パターン分類による独居高年齢者の非日常検出, 川崎医療福祉学会誌, Vol.15, No.1, pp.175-181 (2005).
- 3) L. Bao and S.S. Intille: Activity recognition from user -annotated acceleration data, in Proceedings. of Pervasive, Vol.LNCS 3001, A. Ferscha and F. Mattern edition, Springer-Verlag, Berlin Heidelberg, pp.1-17 (2004).
- 4) 田淵勝宏: 加速度センサを用いた日常行動識別におけるデータ収集条件の識別性能への影響評価, 電子情報通信学会技術研究報告, Vol.106, No.73, pp.43-48 (2006).
- 5) 川原圭博: 小型無線センサを用いたコンテキスト推定とそのアプリケーション, 特別非常利活動法人ウェアラブルコンピューティング研究会報告, Vol.1, No.3, pp.2-6 (2011).
- 6) J.Han, M.Kamber, and J.Pei: Data Mining, Concepts and Techniques, Morgan Kaufmann (2011).
- 7) H. Sugimura, and K. Matsumoto: Classification system for time series data based on feature pattern extraction, Man, and Cybernetics SMC, pp.1340-1345 (2011).
- 8) 宮崎雄一郎: ユーザの行動に合わせたサービス実現のための行動推定技術の開発, NTT DoCoMo テクニカル・ジャーナル, Vol.17, No.3, pp.55-61 (2009).
- 9) Kanungo, T. and Mount, D.M. and Netanyahu, N.S. and Piatko, C.D. and Silverman, R. and Wu, A.Y.: An efficient k-means clustering algorithm: Analysis and implementation, Pattern Analysis and Machine Intelligence, Vol.24, No.7, pp.881-892 (2002).